



aivancity

La Grande Ecole de l'IA & de la Data

Paris Île-de-France · Nice Côte d'Azur



Data Wrangling

Gestion de projet

Plan du cours

- ❖ La gestion de projet
- ❖ La gestion d'un projet data wrangling
- ❖ lab

Etapes du data wrangling



Exemple type des étapes du data wrangling

Etapes clé du data wrangling

Découverte (Discovering)

Explorer et comprendre les données brutes.

Structuration (Structuring)

Organiser les données dans un format clair et cohérent.

Nettoyage (Cleaning)

Corriger les erreurs, doublons et valeurs manquantes.

Enrichissement (Enriching)

Ajouter ou calculer de nouvelles informations utiles.

Validation (Validating)

Vérifier la cohérence et la qualité des données.

Publication (Publishing)

Exporter les données prêtes pour l'analyse ou le machine learning.

Etape 1 - Découverte (Discovering)

- ❖ Se familiariser avec les données pour comprendre leur structure et leur contenu.
- ❖ Identifier les tendances, motifs et problèmes (valeurs manquantes, incohérences).

Exemple : Explorer un fichier de ventes pour comprendre la signification de chaque colonne et repérer les valeurs manquantes ou inhabituelles.

Cette étape oriente toutes les actions suivantes du nettoyage et de l'analyse.



Etape 2 - Structuration (Structuring)

Transformer les données brutes pour les rendre exploitables et faciles à analyser.

Organiser les informations selon une structure claire (tableaux, colonnes, formats normalisés).

Exemple : Convertir un fichier de ventes sous forme de texte libre en un tableau structuré.

La forme finale dépend du modèle d'analyse ou de l'outil que l'on souhaite utiliser.



Etape 3 - Nettoyage (Cleaning)

Éliminer les erreurs ou incohérences qui peuvent fausser l'analyse.

Garantir des données fiables, cohérentes et prêtes à être exploitées.

Exemples d'actions :

- *Supprimer les cellules ou lignes vides*
- *Retirer les valeurs aberrantes (outliers)*
- *Uniformiser les formats (dates, majuscules/minuscules, unités, etc.)*

Le nettoyage est une étape clé pour assurer la qualité et la crédibilité des résultats.



Etape 4 - Enrichissement (Enriching)

Vérifier si les données existantes sont suffisantes pour répondre aux besoins du projet

Si nécessaire, ajouter ou compléter les données à partir d'autres sources fiables.

Exemples d'actions : Ajouter des informations clients issues d'une autre base de données
Créer de nouvelles variables calculées (ex. revenu annuel à partir du salaire mensuel)

Chaque nouvelle donnée intégrée doit être nettoyée et vérifiée comme les données d'origine.



Etape 5 - Validation (Validating)

Vérifier que les données sont cohérentes, exactes et de qualité suffisante pour l'analyse.

S'assurer qu'aucune erreur, valeur manquante ou incohérence n'a échappé au nettoyage.

Exemples d'actions : Contrôler que les âges sont compris entre des valeurs réalistes (ex. 18-65 ans)

Vérifier la correspondance entre les totaux et les sous-totaux

Détecter d'éventuelles doublons restants

Cette étape permet de confirmer que les données sont fiables et prêtes à être analysées.



Etape 6 - Publication (Publishing)

Une fois les données validées, elles peuvent être partagées ou diffusées pour l'analyse.

Mettre les données à disposition des équipes ou décideurs de l'organisation.

Exemples de diffusion :

Exporter les données nettoyées au format CSV, Excel ou base de données

Créer un rapport ou tableau de bord (Power BI, Tableau, etc.)

Partager un fichier collaboratif pour exploitation par d'autres services

Le format de publication dépend du type de données et des objectifs de l'organisation.



Gestion de projet

data wrangling



Le cycle de vie en cascade

2 mois



Recueillir
les exigences

1 mois




Analyser

4 mois



Concevoir

12 mois



Coder

2 mois




Intégrer, tester & effectuer
le contrôle qualité

Que se passe-t-il lorsqu'on découvre
à ce stade des changements par
rapport aux exigences ?

Et à ce
stade ?

Et à celui-ci
?

Le cycle de vie en V



#Voyons les principes

Agilité en 7 mns :


<https://youtu.be/JRSTNJcjDug?feature=shared>

Scrum en 8 mns :

https://www.youtube.com/watch?v=Hxj47ie_Flw


SCRUM

MÉTHODE SCRUM



source : tuleap.org

Scrum au quotidien




C'est quoi le
backlog
produit?

#Backlog produit


- Le backlog produit est une liste priorisée de fonctionnalités à faire pour construire ou développer un produit.



#Backlog produit




Que contient
le backlog
produit?



Comment faire ?

Niveaux de spécification



<https://www.qualitystreet.fr/2022/03/21/epic-vous-avez-dit-epic-definition-et-explications/>

C est quoi la
vision produit?

#la vision produit (objectif produit)

Product Vision - Be the leading online Bakery in the UK.

Product Goal 1 - Launch a website that allows sales to customers inside London.

Product Goal 2 - Expand production/delivery capability to allow sales to customers UK wide.

Product Goal 3 - Expand online presence via the Apple and Google Play app stores.

#la vision produit (objectif produit)

Product Goal 1 - Launch a website that allows sales to customers inside London.

Sprint Goal 1 - Create basic website structure.

Sprint Goal 2 - Build capability to list & purchase products using a credit card.

Sprint Goal 3+ - ... as many more Sprint Goals as needed.

Sprint Goal X - Launch the website and fulfil the first orders.

Product Goal 1 has now been fulfilled.

Product Goal 2 - Expand production/delivery capability to allow sales to customers UK wide.

Sprint Goal 1 - Find UK wide supply partners.

Sprint Goal 2 - Review potential partners and select 1-3.

Sprint Goal 3+- ... as many more Sprint Goals as needed.

Sprint Goal X - Beta launch of national capability with invited customers only and fulfil first orders.

Product Goal 2 has now been fulfilled.

Product Goal 3- Expand online presence via the Apple and Google Play app stores.

Sprint Goal 1 - Build basic iOS app.

Sprint Goal 2 - Build capability to list products.

#la vision produit (objectif produit)

Sprint Goal 3+ - ... as many more Sprint Goals as needed.

Sprint Goal X - Launch the app via the Apple App Store.

At this point, it was discovered that the costs of developing the Google Play app would outweigh the benefits. As a result, this Product Goal was abandoned and a new Product Goal created.

C est quoi une
User Story?

En tant que client d'une banque,
Je veux visualiser les opérations passées sur mon compte
Afin de les rapprocher des dépenses que j'ai effectuées

Une priorité métier

Macro : Must / Should / Could / Wish


Micro : 1, 2, 3, 4, 5, 6 ...

Une valeur métier

10, 20, 30, ...

Une complexité technique

1, 2, 3, 5, 8, 13, 20, 50, 100



Les cas de gestion

Exemple: Par défaut, seules les 20 dernières opérations sont visualisées


Les tests fonctionnels

- Exemple: Pour le client d'ID 1584, les opérations passées sont visualisées comme indiqué dans la maquette.
- Exemple: Pour le client d'ID 1677, il n'existe aucune opération passée sur son compte. Le message « Aucune opération » apparaît comme indiqué dans la maquette.

Exemple

ID	Story	Estimation	Priority
6	As a general user I want to register a new account.	3	1
2	As a member I want to sign-in my account.	2	2
5	As a member I want to sign-out my account.	1	3
10	As an administrator I want to disallow suspicious registration attempts.	2	4
1	As a member I want to add new items into shopping cart.	5	5
3	As a member I want to checkout shopping cart.	7	6
4	As a member I want to track the delivery.	2	7
9	As a member I want to record delivery addresses.	1	8
7	As a member I want to cancel order.	1	9
8	As an administrator I want to see the list of accounts logged in.	2	10
Total		26	

Product backlog refinement




Le Product Backlog est continuellement affiné pour augmenter la compréhension, la granularité et la transparence.

Le raffinement ne consomme généralement pas plus de 10 % de la capacité de l'équipe de développement.

Le passage des PBI en mode « Prêts » est déterminé par l'équipe de développement.

KANBAN

Constitution d'un tableau mural permettant l'affectation de chaque tâche à une étape du flux




Pourquoi?

- **Suivi collaboratif**
(avancement, synchronisation, identification des problèmes, application des principes Kanban)

Définir le DoD:

- Le Definition of Done est l'ensemble des critères qui permettent de considérer une étape du travail comme terminée et de tirer la carte à l'étape suivante

Les limites kanban indiquent le nombre de tâches pouvant être placées dans chaque étape du processus ;
il peut s'agir de limite haute ou de limite basse



« Cesser de commencer, commencer par terminer »!

■ Pourquoi limiter le WIP (TAF) ?

- **Améliorer la productivité:** en effet la commutation fréquente entre tâches nuit à la productivité
- **Eviter les gaspillages de surproduction à un instant t:** on « produit » et on envoie le juste nécessaire à l'étape suivante

La Démarche Itérative d'un Projet DATA et Business Intelligence

1




**Définir : Identifier
les besoins**

2



**Prototyper : Créer des
versions préliminaires**

3




**Valider : Tester et
ajuster**

4



**Produire : Mettre en
œuvre la solution finale**

DATAOPS



Exemples

Une équipe data typique comprend :

- **Product Owner (PO)** : définit les besoins métiers et les priorités (ex. : quels indicateurs suivre, quelles questions business résoudre).
- **Scrum Master / Agile Coach** : veille à la méthode et à la fluidité du travail.
- **Data Engineer** : collecte, nettoie et prépare les données.
- **Data Scientist / Analyst** : modélise, visualise et interprète les données.
- **Stakeholders (parties prenantes)** : utilisateurs métiers, direction, clients internes.

Exemples

Définir la vision et les objectifs

Avant de commencer, il faut clarifier :

- Quels problèmes métiers veut-on résoudre ?
- Quels indicateurs ou modèles vont être produits ?
- Quelles sources de données sont disponibles ?

On formalise cela dans une vision produit et un Product Backlog (la liste des tâches ou “User Stories”).

Exemples

Exemples de user stories :

- “En tant que directeur marketing, je veux voir le taux de conversion par campagne pour ajuster mon budget.”
- “En tant que data scientist, je veux un jeu de données propre et complet pour entraîner mon modèle.”
- Chaque story doit être testable et apporter de la valeur métier.

Cas pratique : FastColis

Une entreprise de livraison (“FastColis”) migre sa data platform on-premise (serveurs locaux) vers le cloud (Azure).

L’objectif : récupérer, nettoyer, transformer et centraliser les données (colis, clients, tournées, véhicules, incidents) pour permettre une exploitation future via Power BI et du machine learning.

Backlog produit

Epic	Feature	User Story
EPIC 1 : Migration & intégration des données sources	FEAT 1.1 : Extraction des données on-premise	US 1.1.1 : En tant que data engineer, je veux extraire les données des serveurs SQL locaux pour les transférer vers le cloud.
EPIC 1	FEAT 1.2 : Stockage sur Data Lake	US 1.2.1 : En tant qu'architecte data, je veux stocker les données extraites dans des conteneurs structurés par domaine.
EPIC 2 : Nettoyage et préparation des données	FEAT 2.1 : Détection et suppression des doublons	US 2.1.1 : En tant que data wrangler, je veux supprimer les doublons dans la table "colis" pour garantir la qualité.
EPIC 2	FEAT 2.2 : Standardisation des formats	US 2.2.1 : En tant que data wrangler, je veux harmoniser les formats de date, devises et codes pays.
EPIC 3 : Gouvernance & validation	FEAT 3.1 : Contrôles de qualité	US 3.1.1 : En tant que responsable data, je veux un rapport de validation automatique des anomalies détectées.
EPIC 3	FEAT 3.2 : Documentation et traçabilité	US 3.2.1 : En tant qu'équipe data, je veux documenter le dictionnaire de données et les étapes de nettoyage.

Sprint 1 Exemple

User Story	Tâches techniques (Dev Team)	Responsable
US 1.1.1	Identifier tables sources dans SQL Server	Data Engineer
US 1.1.1	Configurer pipeline d'ingestion Azure Data Factory	Data Engineer
US 1.1.1	Test de transfert et logs d'exécution	Data Engineer
US 1.2.1	Créer containers Azure Blob	Cloud Architect
US 1.2.1	Vérifier formats et intégrité des fichiers	QA / Analyst
US 2.1.1	Script de détection et suppression des doublons	Data Wrangler
US 2.2.1	Script de conversion de formats de date et devise	Data Wrangler
US 3.1.1	Création rapport de contrôle (Python)	Data Analyst
US 2.2.1	Script de conversion de formats de date et devise	Data Wrangler

Projet Data – Analyse internationale de la satisfaction client

FastColis est une entreprise de livraison de colis présente dans plusieurs pays (France, Espagne, Allemagne, Maroc et Canada).

Chaque filiale locale mène régulièrement des enquêtes de satisfaction client pour mesurer la qualité de ses services :

- Délai de livraison
- Relation avec le livreur
- État du colis
- Disponibilité du service client

Projet Data – Analyse internationale de la satisfaction client

Mais les outils d'enquête utilisés diffèrent selon les pays :

- En France, les données sont stockées dans un fichier Excel avec des notes sur 5.
- En Espagne, le format est JSON et les réponses vont de “*Bajo / Medio / Alto*”.
- Au Canada, la notation est sur 10.
- Au Maroc, les enquêtes sont saisies sous forme de texte libre.
- En Allemagne, les produits ont d'autres codes (ex. : *PAK_001* au lieu de *COLIS_STANDARD*).

Projet Data – Analyse internationale de la satisfaction client

Mettre en place une plateforme de données centralisée qui permet de :

1. Collecter automatiquement les enquêtes de satisfaction de chaque pays.
2. Nettoyer et structurer les données selon un format unique.
3. Créer un référentiel produit mondial, car chaque pays utilise ses propres appellations.
4. Normaliser les scores de satisfaction (toutes les échelles converties sur 5).
5. Permettre des requêtes IA du type :

“Sur le périmètre France, quel est le degré de satisfaction pour le service après-vente ?”

“Quel produit obtient la plus faible satisfaction moyenne au niveau global ?”

Projet Data – Analyse internationale de la satisfaction client

Exemples :

- *En tant que Data Engineer, je veux centraliser toutes les enquêtes dans un format unique pour permettre l'analyse globale.*
- *En tant que Data Analyst, je veux accéder à des données propres pour calculer la satisfaction moyenne par pays.*
- *En tant que Data Steward, je veux créer un référentiel produit unique pour harmoniser les noms de produits.*

Travail a faire


Analyse du besoin

- Définir les objectifs business : comparabilité, qualité, rapidité d'analyse.
- Identifier les principales contraintes (formats différents, absence de référentiel, etc.).

Décrire le product backlog et le sprint1 backlog

Vous pouvez créer des exemples de fichiers fictifs et realiser le projet !

Exemple Projet CO2



Exemple Projet CO2

Tâche	Objectif
(1)	Atelier Métier : Comprendre les données transports et Indicateur environnementaux par site
(2)	Atelier métier : Comprendre le fonctionnement actuel du calcul CO2
(3)	Présentation des solutions envisagées au métier
(4)	Présentation des spécifications des données TMS
(5)	Atelier SI : Définition de l'architecture sur la plateforme de service
(6)	Atelier SI : Résultat Etude pour générer les paramètres de calcul de CO2
(7)	Préparer le plan de recette

Projet Data Wrangling – Calculateur CO₂ logistique intelligent

Objectif global du projet

Créer un modèle prédictif et explicatif d'émissions de CO₂ par colis, basé sur :

- Les données internes disponibles (flashage colis, parcours logistique, distances approximatives, transporteurs),
- Les données externes ou dérivées (moyenne d'émission par mode de transport, zones géographiques, regroupement d'envois),
- Et des estimations machine learning là où les données manquent (via apprentissage supervisé).

Projet Data Wrangling – Calculateur CO₂ logistique intelligent

Le but :

Proposer à nos clients grands comptes (Amazon, Vinted, etc.) un calculateur de CO₂ par colis ou par commande, capable d'estimer les émissions même si la chaîne logistique est partiellement observée.

Objectif Data Wrangling

- L'objectif du projet est de construire un dataset unifié et propre pour entraîner un modèle de prédiction CO₂ à partir de données hétérogènes, souvent incomplètes.

Projet Data Wrangling – Calculateur CO₂ logistique intelligent

Contexte logistique

Chaîne type :

1. **Colis international** : expédié d'un centre étranger ou partenaire sous-traitant.
2. **Plateforme d'entrée** (ex : Roissy, Rotterdam...) : premier scan ("flashage").
3. **Plateforme de tri régionale** : second scan, regroupement et réétiquetage.
4. **Centre local / dernier km** : scan avant distribution.
5. **Livraison finale** (à vélo, camion, point relais...).

Projet Data Wrangling – Calculateur CO₂ logistique intelligent

Données disponibles :

- Événements de flashage (timestamp + localisation)
- **Transporteurs** internes et sous-traitants (ID partiel, pas toujours renseigné)
- **Données SAP** (facturation, clients, produits, poids, mode de paiement)
- **Type de livraison** (standard, express, écologique, internationale)
- **Poids et volume** du colis
- **Pays d'origine et destination**

Projet Data Wrangling – Calculateur CO₂ logistique intelligent

Étape	Description	Livrables
1. Découverte des données	Identifier les sources (SAP, flashage, fichiers transporteurs, tables externes) et comprendre leurs schémas.	Dictionnaire de données + diagramme de flux
2. Ingestion	Charger les données depuis les différentes sources (CSV, SQL, API, logs).	Scripts d'importation / pipeline
3. Structuration et nettoyage	Uniformiser les colonnes, gérer les doublons, valeurs manquantes, formats de date, unités.	Dataset structuré niveau "Raw Clean"
4. Enrichissement	Ajouter des données externes (distances, modes de transport, facteurs CO ₂ moyens).	Table enrichie (poids, distance, mode)
5. Mapping et Feature Engineering	Créer des variables explicatives (type de trajet, pays d'origine, distance moyenne, type transporteur).	Table "Curated" prête pour ML
6. Validation	Vérifier la cohérence (par ex. : pas de trajet négatif, distances cohérentes).	Rapport qualité + statistiques descriptives

Données à construire (exemples de colonnes finales)

Colonne	Description	Source / Calcul
tracking_id	Identifiant unique du colis	SAP / système interne
date_first_scan	Date du premier flashage	Événements logistiques
date_last_scan	Date de livraison ou dernier flashage	Événements logistiques
pays_origine / pays_destination	Codes ISO	SAP
poids_kg	Poids du colis	SAP
volume_m3	Volume calculé à partir des dimensions	SAP
nb_plateformes	Nombre de plateformes traversées	Événements flashage
distance_estimee_km	Calculée via géolocalisation ou API distance	Données GPS / API
mode_transport	“Air”, “Train”, “Camion”, “Vélo”	Transporteurs / règles métier
facteur_emission	gCO ₂ /km selon le mode de transport	Table référentielle
emission_estimee	CO ₂ total estimé (poids × distance × facteur)	Calcul dérivé
emission_ml	CO ₂ prédit par modèle ML	Modèle d'apprentissage supervisé

Exemple de pipeline de données (simplifié)

[Sources brutes]

- SAP (colis, poids, facturation)
- Flashages (dates, sites, coordonnées)
- Table transporteurs (type, mode)
- Table facteurs CO₂ (par mode)
- API distance (Google / OpenRouteService)



[Data Wrangling]

- Nettoyage / fusion / mapping
- Création variables distance, volume, nb_étapes



[Dataset final]

- Emission estimée par colis
- Dataset prêt pour machine learning

The background features a dark blue gradient with a complex network of glowing white and light blue lines and dots, resembling a data network or neural network. On the left side, there is a faint, circular logo with the letters 'ai' inside, surrounded by concentric circles and lines.

aivancity

La Grande Ecole de l'IA & de la Data

———— Paris Île-de-France · Nice Côte d'Azur